m03 v01 store sales prediction

September 12, 2021

1 0.0. IMPORTS

```
[1]: import math
  import numpy as np
  import pandas as pd
  import inflection

import seaborn as sns

from matplotlib import pyplot as plt
  from IPython.core.display import HTML
  from IPython.display import Image
```

1.1 0.1. Helper Functions

```
[3]: jupyter_settings()
```

Populating the interactive namespace from numpy and matplotlib <IPython.core.display.HTML object>

1.2 0.2. Loading data

```
[4]: df_sales_raw = pd.read_csv( '.../data/train.csv', low_memory=False )
    df_store_raw = pd.read_csv( '.../data/store.csv', low_memory=False )

# merge
    df_raw = pd.merge( df_sales_raw, df_store_raw, how='left', on='Store' )
```

2 1.0. PASSO 01 - DESCRICAO DOS DADOS

```
[5]: df1 = df_raw.copy()
```

2.1 1.1. Rename Columns

2.2 1.2. Data Dimensions

```
[7]: print( 'Number of Rows: {}'.format( df1.shape[0] ) )
print( 'Number of Cols: {}'.format( df1.shape[1] ) )

Number of Rows: 1017209
Number of Cols: 18
```

2.3 1.3. Data Types

```
[8]: df1['date'] = pd.to_datetime( df1['date'] )
    df1.dtypes
```

```
[8]: store int64
    day_of_week int64
    date datetime64[ns]
    sales int64
    customers int64
    open int64
```

int64 promo state_holiday object school_holiday int64 object store_type assortment object competition_distance float64 float64 competition_open_since_month competition_open_since_year float64 int64 promo2 float64 promo2_since_week float64 promo2_since_year promo_interval object dtype: object

2.4 1.4. Check NA

[9]: df1.isna().sum()

[9]: store 0 0 day_of_week date 0 0 sales customers 0 open 0 promo 0 0 state_holiday school_holiday 0 0 store_type 0 assortment competition_distance 2642 competition open since month 323348 competition_open_since_year 323348 promo2 0 508031 promo2_since_week promo2_since_year 508031 promo_interval 508031 dtype: int64

2.5 1.5. Fillout NA

[10]: df1.sample()

[10]: store day_of_week date sales customers open promo state_holiday school_holiday store_type assortment competition_distance competition_open_since_month competition_open_since_year promo2 promo2_since_week promo2_since_year promo_interval 575825 156 5 2014-01-31 6454 714 1 0

```
0 0 a a 2020.0
2.0 2011.0 1 14.0 2011.0
Mar,Jun,Sept,Dec
```

```
[11]: #competition distance
      df1['competition distance'] = df1['competition distance'].apply( lambda x:___
      \rightarrow200000.0 if math.isnan(x) else x)
      #competition_open_since_month
      df1['competition_open_since_month'] = df1.apply( lambda x: x['date'].month if_
      →math.isnan(x['competition open since month']) else
      →x['competition_open_since_month'], axis=1 )
      #competition_open_since_year
      df1['competition_open_since_year'] = df1.apply( lambda x: x['date'].year if_
      →math.isnan(x['competition_open_since_year']) else

      →x['competition_open_since_year'], axis=1 )
      #promo2 since week
      df1['promo2_since_week'] = df1.apply( lambda x: x['date'].week if math.isnan(_
      →x['promo2 since week'] ) else x['promo2 since week'], axis=1 )
      #promo2_since_year
      df1['promo2_since_year'] = df1.apply( lambda x: x['date'].year if math.isnan(__
      →x['promo2_since_year'] ) else x['promo2_since_year'], axis=1 )
      #promo interval
      month_map = {1: 'Jan', 2: 'Fev', 3: 'Mar', 4: 'Apr', 5: 'May', 6: 'Jun', U
      →7: 'Jul', 8: 'Aug', 9: 'Sep', 10: 'Oct', 11: 'Nov', 12: 'Dec'}
      df1['promo_interval'].fillna(0, inplace=True )
      df1['month map'] = df1['date'].dt.month.map( month map )
      df1['is promo'] = df1[['promo interval', 'month map']].apply( lambda x: 0 if__

¬x['promo_interval'] == 0 else 1 if x['month_map'] in x['promo_interval'].
       →split(',') else 0, axis=1)
```

```
[12]: df1.isna().sum()
```

```
[12]: store 0
day_of_week 0
date 0
sales 0
customers 0
open 0
promo 0
```

```
state_holiday
                                  0
                                  0
school_holiday
store_type
                                  0
                                  0
assortment
competition_distance
                                  0
competition_open_since_month
                                  0
competition_open_since_year
                                  0
                                  0
promo2
promo2 since week
                                  0
promo2_since_year
                                  0
promo interval
                                  0
month_map
                                  0
is promo
                                  0
dtype: int64
```

2.6 1.6. Change Data Types

2.7 1.7. Descriptive Statistics

```
[14]: num_attributes = df1.select_dtypes( include=['int64', 'float64'] )
cat_attributes = df1.select_dtypes( exclude=['int64', 'float64', 'datetime64[ns]'] )

→ 'datetime64[ns]'] )
```

2.7.1 1.7.1. Numerical Atributes

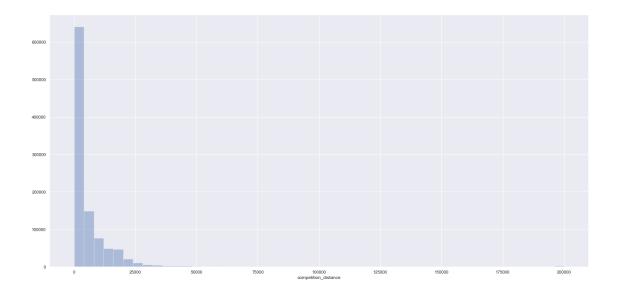
```
[15]: # Central Tendency - mean, meadina
  ct1 = pd.DataFrame( num_attributes.apply( np.mean ) ).T
  ct2 = pd.DataFrame( num_attributes.apply( np.median ) ).T

# dispersion - std, min, max, range, skew, kurtosis
  d1 = pd.DataFrame( num_attributes.apply( np.std ) ).T
  d2 = pd.DataFrame( num_attributes.apply( min ) ).T
  d3 = pd.DataFrame( num_attributes.apply( max ) ).T
  d4 = pd.DataFrame( num_attributes.apply( lambda x: x.max() - x.min() ) ).T
  d5 = pd.DataFrame( num_attributes.apply( lambda x: x.skew() ) ).T
  d6 = pd.DataFrame( num_attributes.apply( lambda x: x.kurtosis() ) ).T
```

[15]:			attributes	min	max	range	mean
	median	std	skew	kurtosi	S	_	
	0		store	1.0	1115.0	1114.0	558.429727
	558.0	321.908493	-0.000955	-1.200524			
	1		day_of_week	1.0	7.0	6.0	3.998341
	4.0	1.997390	0.001593 -1	.246873			
	2		sales	0.0	41551.0	41551.0	5773.818972
	5744.0	3849.924283	0.641460	1.77837	5		
	3		customers	0.0	7388.0	7388.0	633.145946
	609.0	464.411506	1.598650	7.091773			
	4		open	0.0	1.0	1.0	0.830107
	1.0	0.375539 -1	.758045 1	.090723			
	5		promo	0.0	1.0	1.0	0.381515
	0.0	0.485758 0	.487838 -1	.762018			
	6	sch	ool_holiday	0.0	1.0	1.0	0.178647
		0.383056 1					
		competiti	_			199980.0	5935.442677
	2330.0 12547.646829 10.242344 147.789712						
	_	etition_open_			12.0	11.0	6.786849
	7.0		0.042076 -1				
	-	petition_open	•			115.0	2010.324840
		5.515591					
	10		promo2		1.0	1.0	0.500564
		0.500000 -0					
		promo2			52.0	51.0	23.619033
		14.310057					
		promo2				6.0	2012.793297
		1.662657					
	13		is_promo		1.0	1.0	0.155231
	0.0	0.362124 1	.904152 1	.625796			

```
[16]: sns.distplot( df1['competition_distance'], kde=False )
```

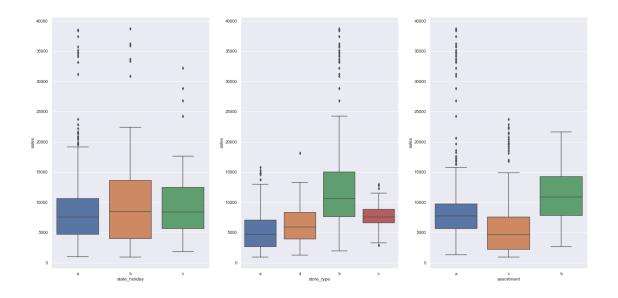
[16]: <matplotlib.axes._subplots.AxesSubplot at 0x162de2370>



2.7.2 1.7.2. Categorical Atributes

```
[17]: cat_attributes.apply( lambda x: x.unique().shape[0] )
[17]: state_holiday
     store_type
                         4
     assortment
                         3
     promo_interval
                         4
     month_map
                        12
      dtype: int64
[18]: aux = df1[(df1['state_holiday'] != '0') & (df1['sales'] > 0)]
      plt.subplot( 1, 3, 1 )
      sns.boxplot( x='state_holiday', y='sales', data=aux )
      plt.subplot( 1, 3, 2 )
      sns.boxplot( x='store_type', y='sales', data=aux )
      plt.subplot( 1, 3, 3 )
      sns.boxplot( x='assortment', y='sales', data=aux )
```

[18]: <matplotlib.axes._subplots.AxesSubplot at 0x106f06dc0>



3 2.0. PASSO 02 - FEATURE ENGINEERING

[19]: df2 = df1.copy()

3.1 2.1. Mapa Mental de Hipoteses

[20]: Image('img/MindMapHypothesis.png') [20]: coggle Volume Compra Perto Escola Numeros Filhos Bairro Localizacao Salario Clientes Age Urbano Profissao Centro Perto Hospital Familia Numero de Funcionarios Frequencia Compra Estoque Lojas Tamanho DAILY STORE SALES Sortimento Marketing Competidores Exposicao Loja Feriados Preco Semana do Ano **Produtos** Quantidade Em Stock Dia Promocao Temporal Mes Hora Final de Semana

Saldao, Sales

3.2 2.2. Criacao das Hipoteses

3.2.1 2.2.1. Hipoteses Loja

- 1. Lojas com número maior de funcionários deveriam vender mais.
- 2. Lojas com maior capacidade de estoque deveriam vender mais.
- 3. Lojas com maior porte deveriam vender mais.
- 4. Lojas com maior sortimentos deveriam vender mais.
- 5. Lojas com competidores mais próximos deveriam vender menos.
- 6. Lojas com competidores à mais tempo deveriam vendem mais.

3.2.2 2.2.2. Hipoteses Produto

- 1. Lojas que investem mais em Marketing deveriam vender mais.
- 2. Lojas com maior exposição de produto deveriam vender mais.
- 3. Lojas com produtos com preço menor deveriam vender mais.
- 5. Lojas com promoções mais agressivas (descontos maiores), deveriam vender mais.
- 6. Lojas com promoções ativas por mais tempo deveriam vender mais.
- 7. Lojas com mais dias de promoção deveriam vender mais.
- 8. Lojas com mais promoções consecutivas deveriam vender mais.

3.2.3 2.2.3. Hipoteses Tempo

- 1. Lojas abertas durante o feriado de Natal deveriam vender mais.
- 2. Lojas deveriam vender mais ao longo dos anos.
- 3. Lojas deveriam vender mais no segundo semestre do ano.
- 4. Lojas deveriam vender mais depois do dia 10 de cada mês.
- 5. Lojas deveriam vender menos aos finais de semana.
- 6. Lojas deveriam vender menos durante os feriados escolares.

3.3 2.3. Lista Final de Hipóteses

- 1. Lojas com maior sortimentos deveriam vender mais.
- 2. Lojas com competidores mais próximos deveriam vender menos.
- 3. Lojas com competidores à mais tempo deveriam vendem mais.
- 4. Lojas com promoções ativas por mais tempo deveriam vender mais.

- 5. Lojas com mais dias de promoção deveriam vender mais.
- 7. Lojas com mais promoções consecutivas deveriam vender mais.
- 8. Lojas abertas durante o feriado de Natal deveriam vender mais.
- 9. Lojas deveriam vender mais ao longo dos anos.
- 10. Lojas deveriam vender mais no segundo semestre do ano.
- 11. Lojas deveriam vender mais depois do dia 10 de cada mês.
- 12. Lojas deveriam vender menos aos finais de semana.
- 13. Lojas deveriam vender menos durante os feriados escolares.

3.4 2.4. Feature Engineering

```
[21]: # year
     df2['year'] = df2['date'].dt.year
     df2['month'] = df2['date'].dt.month
      # day
     df2['day'] = df2['date'].dt.day
      # week of year
     df2['week_of_year'] = df2['date'].dt.weekofyear
      # year week
     df2['year_week'] = df2['date'].dt.strftime('%Y-%W')
      # competition since
     df2['competition_since'] = df2.apply( lambda x: datetime.datetime(__
      →month=x['competition_open_since_month'],day=1 ), axis=1 )
     df2['competition\_time\_month'] = ((df2['date'] - df2['competition\_since'])/30_{\cup}
      →).apply( lambda x: x.days ).astype( int )
      # promo since
     df2['promo_since'] = df2['promo2_since_year'].astype( str ) + '-' +__

→df2['promo2_since_week'].astype( str )
     df2['promo_since'] = df2['promo_since'].apply( lambda x: datetime.datetime.
      \rightarrowstrptime( x + '-1', '%Y-%W-%w' ) - datetime.timedelta( days=7 ) )
     df2['promo_time_week'] = ( ( df2['date'] - df2['promo_since'] )/7 ).apply(__
      →lambda x: x.days ).astype( int )
      # assortment
```

4 3.0. PASSO 03 - FILTRAGEM DE VARIÁVEIS

```
[22]: df3 = df2.copy()
```

4.1 3.1. Filtragem das Linhas

```
[23]: df3 = df3[(df3['open'] != 0) & (df3['sales'] > 0)]
```

4.2 3.2. Selecao das Colunas

```
[24]: cols_drop = ['customers', 'open', 'promo_interval', 'month_map']
df3 = df3.drop( cols_drop, axis=1 )
```